SALES FORECASTING — RETAIL SUPERSTORE

ACA 1 · Aprendizaje Automático · Especialización en Inteligencia Artificial · CUN

9.800	18	209	157	$4.196,67	500
REGISTROS	VARIABLES	SEMANAS	OBS. MODELADO	MAE CV TEMPORAL	ÁRBOLES RF

1 · PROBLEMA Y OBJETIVO

Pronosticar ventas semanales a partir del histórico de Retail Superstore utilizando modelos clásicos de Machine Learning y evaluar su desempeño.

2 · DATOS Y PREPARACIÓN

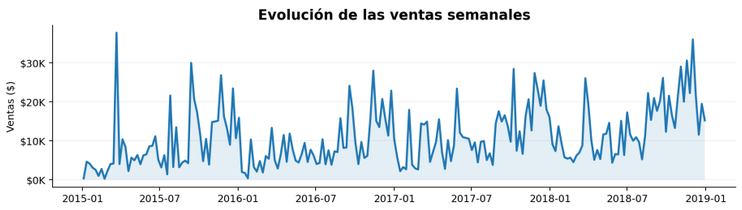
9.800 registros · 18 variables
Periodo 2015–2018 · 0 duplicados exactos · 11 nulos en Postal Code.
Agregación semanal: 209 semanas; 157 observaciones utilizables para modelado.

3 · METODOLOGÍA

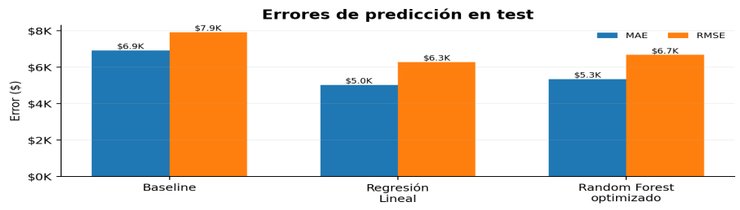
EDA → limpieza → temporalidad → features → baseline → modelos → TimeSeriesSplit → optimización → pronóstico → Streamlit

Features: calendario, rezagos 1/2/4/8/13/26/52 y medias móviles 4/8/13.

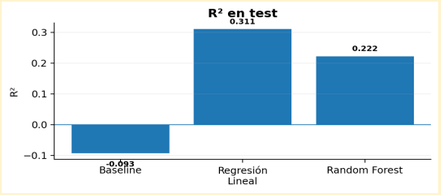
4 · COMPORTAMIENTO DE LAS VENTAS



5 · COMPARACIÓN DE ERRORES EN TEST



6 · ¿QUÉ DICE EL TEST?



Regresión Lineal presenta el mejor resultado en este bloque de test: menor MAE y RMSE, y mayor R².

Esto es importante: **no sería correcto afirmar que Random Forest fue elegido porque ganó el test.**

7 · RESULTADOS COMPARATIVOS

MODELO	MAE	RMSE	R²	RESULTADO
Baseline	$6.916,75	$7.914,52	-0,0930	Referencia
Regresión Lineal + cíclicas	**$5.032,24**	**$6.285,68**	**0,3106**	**Mejor test**
Random Forest optimizado	$5.349,13	$6.675,79	0,2224	Despliegue

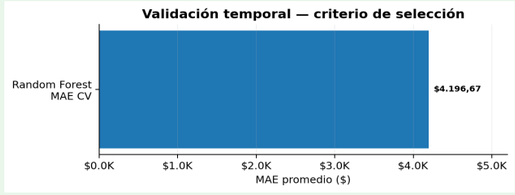
Lectura de métricas del modelo final

MÉTRICA	SIGNIFICADO	RESULTADO RF
MAE	Error absoluto promedio; cuanto menor, mejor.	$5.349,13
RMSE	Penaliza con mayor peso los errores grandes.	$6.675,79
R²	Variabilidad explicada por el modelo.	0,2224
MAE CV temporal	Error promedio durante TimeSeriesSplit.	**$4.196,67**

Ingeniería de variables

FEATURE	FUNCIÓN
Calendario	Captura patrones asociados a año, mes y semana.
Rezagos 1–52	Incorpora información histórica de distintos horizontes.
Medias móviles	Representa nivel reciente y suaviza fluctuaciones.

8 · CRITERIO DE SELECCIÓN



PASO	EVIDENCIA
1. Test	Regresión Lineal gana este bloque de métricas.
2. Validación temporal	Random Forest optimizado: **MAE CV = $4.196,67** usando TimeSeriesSplit.
3. Capacidad	RF permite modelar relaciones no lineales y se adapta al esquema de features temporales.
4. Decisión	**Random Forest optimizado → modelo desplegado en Streamlit.**

Conclusión de la selección: el bloque test por sí solo favorece a la Regresión Lineal. El proyecto selecciona Random Forest para despliegue por el resultado de la validación temporal y por su capacidad para representar relaciones no lineales.

9 · MODELO FINAL

Random Forest Regressor optimizado

500 árboles · profundidad 5 · max_features 0,7 · min_samples_leaf 1.

MAE: $5.349,13 · **RMSE:** $6.675,79 · **R²:** 0,2224

10 · DESPLIEGUE

Streamlit permite seleccionar horizonte de **1, 2, 4 u 8 semanas**, consultar el histórico, visualizar el pronóstico y revisar métricas e importancia de variables.

11 · CONCLUSIONES

La solución integra preparación de datos, ingeniería de variables, validación temporal, comparación de modelos y despliegue. El RF optimizado es el modelo utilizado en la aplicación final.

12 · INTERPRETACIÓN

El pronóstico es una **estimación estadística**. Los errores cuantifican incertidumbre y deben considerarse al tomar decisiones sobre demanda.

REFERENCIA: Luque, G. (2021). *Sales Forecasting - Retail Superstore* [Conjunto de datos]. Kaggle.